

Einsatz digitaler Systeme zur Prozessüberwachung

Ein methodischer Implementierungsansatz zur Verfügbarkeitserhöhung und Qualitätsverbesserung

Alexander Busse,
Tobias Meudt und
Joachim Metternich, Darmstadt

Maschinelles Lernen ermöglicht es, Gesetzmäßigkeiten automatisch aus Eingangsdaten und verknüpften Zielwerten zu „erlernen“ und Vorhersagen abzuleiten. Dies kann in der Produktion zur Prozessstabilisierung genutzt werden. Ein strukturierter Implementierungsansatz ist nötig, der datentechnische Anforderungen definiert und den Nutzen der digitalen zur analogen Problemlösungen abwägt. Am Institut PTW der TU Darmstadt wurde ein solcher Ansatz entwickelt. Erste Versuche zeigen, dass die Methode gezieltes maschinelles Lernen unterstützt und akkurate Vorhersagen zur Prozessstabilisierung ermöglicht.*)

Einleitung

Maschinenparkbetreiber können neben klassischen Methoden der schlanken Produktion aus einer Fülle von digitalen Produkten und Konzepten auswählen, um Prozesse zu verbessern. Diese Lösungen sind i. d. R. jedoch auf die Eigenschaften individueller Wertströme oder Maschinen eines Unternehmens zugeschnitten. Welche Art der Digitalisierung tatsächlich nutzenstiftend eingesetzt werden kann, ist im Kontext stark unterschiedlicher Prozess- und Anlagentypen daher stets fallabhängig zu bewerten. Gleichzeitig ist der erzielbare Nutzen im Vergleich zu den Kosten und unter dem Aspekt möglicher „analoger“ Lösungsansätze (z. B. aus dem Methodenkasten der schlanken Produktion) zu bewerten. Stoßen analoge Lösungen oder bewährte schlanke Metho-

den an ihre Grenzen, kann eine digitale Prozessüberwachung Kausalzusammenhänge identifizieren, um gezielt Maßnahmen zur Prozessstabilisierung einzuleiten, beispielsweise indem Verfügbarkeits- und Qualitätsverluste frühzeitig vorhergesagt und verhindert werden [1].

Aus Daten automatisch Mehrwert erschaffen mithilfe maschinellen Lernens

Die Digitalisierung von Produktionsprozessen bietet Unternehmen die Möglichkeit, durch Verfahren der „intelligenten“ Prozessüberwachung Prozessanomalien frühzeitig zu identifizieren oder vorherzusagen. Hierbei zum Einsatz kommende Verfahren der Datenanalyse – oftmals unter dem Schlagwort „Big Data“ oder „Data Mining“ zusammengefasst – reichen von einer passiven Vergangenheitsbetrachtung bis hin zur aktiven Gestaltung in der Zukunft liegender, antizipierter Ereignisse. Die Anwendungen können in die Subkategorien „Erkennen & Reagieren“ sowie „Vorhersagen & Handeln“ unterteilt werden: Während erstere Abweichungen vom Soll-Prozess automatisch identifizieren und Gegenmaßnahmen reaktiv auslösen, wird bei letzteren ein auftretendes Ereignis frühzeitig aus Daten prognostiziert und Maßnahmen proaktiv eingeleitet [2].

Hierfür werden Prozess-, Maschinen- und Produktdaten erfasst und ausgewer-

tet, wobei „modellbasierte“ und „datenbasierte“ Verfahren unterschieden werden: Während in modellbasierten Verfahren vordefinierte mathematische oder logische Modelle Verwendung finden, die das Systemverhalten beschreiben, werden in datenbasierten Verfahren stochastische Modelle aus der Kombination von Eingangs- und Zielwerten abgeleitet. Ein Verhaltensmodell des Untersuchungsgegenstandes ist nicht nötig, was den Implementierungsaufwand deutlich reduziert. Eine wichtige Gruppe datenbasierter Verfahren ist das „maschinelle Lernen“: Ein künstliches System erlernt aus Trainingsdaten automatisch Muster und Gesetzmäßigkeiten und leitet daraus das stochastische Modell ab, mit dem beispielsweise Prognosen erstellt werden. Hiermit können nach Beendigung einer initialen Trainingsphase auch neue Daten der gleichen Problemstellung beurteilt werden. Damit dies möglich ist müssen dem Algorithmus neben definierten Eingangsdaten (z. B. Leistungsdaten) ebenfalls korrespondierende Zielwerte (z. B. Bauteilqualität) zwecks Modelltraining zur Verfügung gestellt werden. Man spricht in diesem Zusammenhang von „überwachtem“ Lernen, da der Erfolg des Trainings überwacht wird: Nur wenn die durch das Modell prognostizierten Ergebnisse den vorgegebenen Zielwerten möglichst entsprechen, liegt ein Trainingserfolg vor [3, 4].

*) Danksagung

Diese Veröffentlichung entstand im Rahmen des Projekts Mittelstand 4.0-Kompetenzzentrum Darmstadt mit freundlicher Unterstützung des Bundesministeriums für Wirtschaft und Energie. Die Verantwortung für den Inhalt dieser Veröffentlichung liegt bei den Autoren.



Gefördert durch:



Bundesministerium
für Wirtschaft
und Energie

aufgrund eines Beschlusses
des Deutschen Bundestages

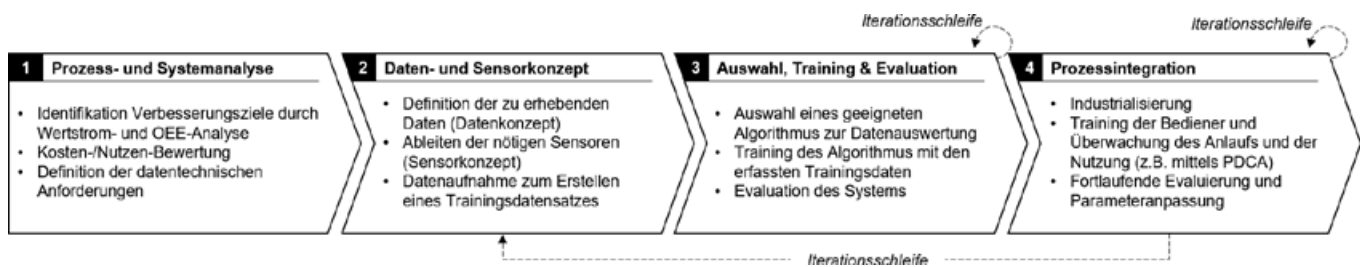


Bild 1. Methodisches Konzept der zielgerichteten Einführung einer digitalen Prozessüberwachung

Die Stärke des maschinellen Lernens im Bereich der automatischen Mustererkennung kann in unterschiedlichen Anwendungen der Kategorien „Erkennen & Reagieren“ und „Vorhersagen & Handeln“ eingesetzt werden, wie z. B. im Bereich der Maschinenausfalldiagnose und -prognose („Predictive Maintenance“) [5, 6].

Ein strukturiertes Vorgehen zur Implementierung digitaler Prozessüberwachung

Um eine gezielte Digitalisierung zum Zwecke der Prozessstabilisierung durchzuführen, ist ein strukturierter Ansatz sinnvoll, der die Dimensionen „Machbarkeit aus datentechnischer Sicht“ und „Monetärer Nutzen“ im Hinblick auf analoge Prozessverbesserung berücksichtigt. Ziel eines solchen Ansatzes ist es, ein ganzheitliches Vorgehen bereitzustellen, mit dem eine digitale Prozessüberwachung in unterschiedlichen Wertströmen situationsspezifisch implementiert werden kann, die eine Kombination aus reaktiven Strategien (z. B. Linienstopp, erweitert durch digitale Fehlererkennung) und proaktiven Strategien durch digitale Fehlervorhersage ermöglicht („Fehler finden, bevor diese zu Defekten werden“). Bild 1 stellt das entwickelte schematische Vorgehensmodell in Anlehnung an [6] dar. Hierbei sei berücksichtigt, dass der Einsatz datenbasierter Verfahren oftmals einen gewissen „Try-and-Error“-Charakter besitzt und daher ggf. mehrere Iterationschleifen entstehen [4].

Um die Methode zu validieren, wurde ein Maschinendemonstrator entwickelt. Die Entwicklung folgt der Idee, unter möglichst realen Produktionsbedingungen und aufbauend auf einer Bestandsmaschine ohne nennenswerte „Intelligenz“ ein digitales Testbed zu implementieren. Im folgenden Abschnitt werden abwechselnd die theoretischen Grundlagen der Methode und ihre praktische Umsetzung entlang der vier Hauptschritte beschrieben.

Prozess- und Systemanalyse

In Anlehnung an das methodische Vorgehen nach Meudt et al. [7] wird in einem ersten Schritt eine Wertstromanalyse mit Fokus auf digitale Chancen und Verbesserungspotenziale durchgeführt. Ergebnis der Analyse ist eine Darstellung möglicher Schwachstellen eines Wertstroms (z. B. in den Dimensionen Verfügbarkeit und Qualität) in Kombination mit den hierzu vorhandenen bzw. benötigten Daten. Nach Eingrenzung möglicher Problemfelder kann die Wertstromanalyse durch eine OEE-Analyse ergänzt werden, in der konkrete Informationen samt Quantifizierung zu Effizienzverlusten im Bereich „Verfügbarkeit“, „Leistungsfähigkeit“ und „Qualität“ erstellt werden [8]. Ausgehend von den identifizierten Problemfeldern gilt es zu beurteilen, ob diese durch digitale Verfahren gelöst werden können oder ob es günstigere, analoge Möglichkeiten gibt.

Ob die Probleme mithilfe digitaler Datenauswertung gelöst werden können, ist vom Anwendungsszenario abhängig, aus dem sich datentechnische Anforderungen ableiten lassen [2]: Bei „Erkennen & Reagieren“ findet ein Training der Systeme auf Identifikation des Normalzustandes statt. Zur Abweichungsidentifikation ist ein Normalzustand zu definieren, der dem System zwecks Training vorgegeben werden kann. Die wesentlichen Prozessparameter, die einen solchen „Normalzustand“ klassifizieren (z. B. Bauteilgeometrien innerhalb Toleranzen), müssen hierfür eindeutig identifiziert und in Daten referenziert werden. „Vorhersagen & Handeln“ bedarf eines stochastischen Modells des Systemverhaltens, aus dem eine Vorhersage über zukünftige Systemzustände zum Zwecke präventiven Handelns abgeleitet wird. Unabdingbar ist hierbei, deterministisches, stetiges Systemverhalten zu erfassen: Um aus gegenwärtigen Systemzuständen auf zukünftige zu schließen, muss überwachbare Kausalität der Systemübergänge existieren. Der Aus-

wahl geeigneter „digitaler Anwendungsfälle“ liegt daher das charakteristische Verhalten möglicher Überwachungsgegenstände im Sinne der zu optimieren Zielgröße zu Grunde. Im Beispiel der Maschinenausfallvorhersage sind Maschinenkomponenten anhand ihres Ausfallverhaltens zu bewerten: nur wenn dieses deterministisch und stetig ist, kann es vorhergesagt werden [9].

Aus monetärer Sicht ist zu beurteilen, ob die nötigen Voraussetzungen für den Einsatz der digitalen Prozessüberwachung im Sinne einer Kosten-Nutzen Bewertung gegeben sind. Hierbei ist zu überprüfen, ob die Kosten der Implementierung, Wartung und Verwendung des Systems dessen Nutzen aufwiegen. Beispielsweise gelingt dies durch Beurteilung der Häufigkeit und Schwere von vermeidbaren Prozessfehlern. Hierbei sind ebenfalls analoge Verfahren zur Fehlerbehebung zu berücksichtigen, die eine digitale Lösung ggf. überflüssig machen können (z. B. Konstruktionsverbesserung an der Maschine) – für eine detaillierte Betrachtung sei auf [10] verwiesen.

Beispiel Prozesslernfabrik – Prozessanalyse und Auswahl des geeigneten Überwachungsgegenstandes

Die Lernfabrik CiP (Center industrieller Produktivität) am PTW bildet auf über 500 m² einen kompletten Wertstrom der Fertigung eines Bauteiles (Pneumatikzylinder) ab, wobei auf den vorhandenen Bestandsmaschinen (Bandsäge, Drehmaschine und Fräsbearbeitungszentrum) Bauteilkomponenten bearbeitet und anschließend zum fertigen Produkt montiert werden. Im untersuchten Produktionsszenario werden im ersten Bearbeitungsschritt auf der Bandsäge Aluminiumrohre abgelängt, die im Fräsbearbeitungszentrum zu fertigen Zylinderböden bearbeitet werden. Ein Werker bedient in Mehrmaschinenbedienung die Maschinen. Parallel hierzu finden weitere Bearbeitungsschritte auf einer Drehmaschine statt.

Im vorliegenden Bearbeitungsszenario wurden aus einer Wertstrom- und OEE-Analyse unterschiedliche Verlustarten entlang des Prozesses in Verbindung mit den Bearbeitungsmaschinen identifiziert. Der Sägeprozess auf der Bandsäge (mittlere Anlagengesamteffizienz von ~62 %) wurde hierbei als potentiell interessant für eine digitale Prozessüberwachung identifiziert: Der durch die Nutzung bedingte Sägebandverschleiß führt regelmäßig sowohl zum Maschinenstopp zwecks Austausch des Bandes als auch zu Ausschuss, sofern durch das Auftreten eines sogenannten „schiefen Schnittes“ (bedingt durch Sägebandverschleiß) Toleranzmaße unterschritten werden. Der Bandverschleiß wird im Status quo durch den Werker reaktiv nach Maschinenstopp erfasst: Ist der Werker zur Zeit des Maschinenstopps nicht an der Maschine, so wird wertvolle Produktionszeit vergeudet. Da es sich beim Zahnverschleiß um einen kontinuierlichen, von der Schnitanzahl abhängigen Prozess handelt, kann ein deterministisches Verschleißverhalten angenommen werden, das sich durch geeignete Datenerfassung voraussagen lässt. Es eignet sich daher für den Anwendungsfall „Vorhersagen & Handeln“. Weitere bekannte Verschleißarten, wie z.B. Zahnabriss oder Bandriss, stellen zufällig auftretende Versagensarten dar, die nur über kurze bis keine Vorwarnzeit verfügen und daher für den Anwendungsfall „Erkennen & Reagieren“ geeignet sind [11]. Analoge Methoden, etwa durch häufigere Inspektionen des Maschinenbedieners oder zeitbasierten Austausch des Sägebandes, können zwar ebenfalls zur Vorbeugung der beschriebenen Probleme verwendet werden, steigern jedoch die Anwesenheitspflicht des Bedieners mit Auswirkung auf die benötigte Personalkapazität. Gleichzeitig werden die Kosten des Sägebandes nicht voll ausgenutzt. Analoge Verfahren wurden daher nicht weiter untersucht.

Daten- und Sensorkonzept

Nach erfolgreicher Prozess- und Systemanalyse werden im Daten- und Sensorkonzept die für den Anwendungsfall notwendige Datenstruktur sowie Sensorik definiert. Eingangsdaten und Zielwerte müssen entsprechend der Anwendungsszenarien erfasst werden, wobei die untersuchte Kausalität von zentraler Bedeutung ist und der Sensorauswahl zugrunde liegt. Durch Expertenwissen, Literatur- oder Patentrecherche können geeignete Sensoren ausgewählt werden. Wesentlicher Er-

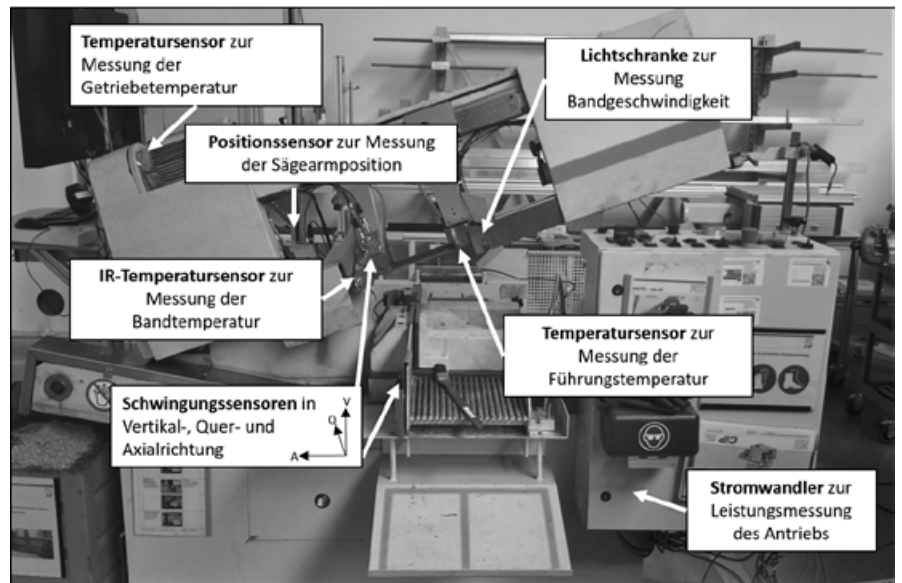


Bild 2. Sensorkonzept der Bandsäge

folgsfaktor maschinellen Lernens liegt zusätzlich in der Datenstruktur und -qualität der Trainingsdaten: Beinhalten die Daten viele redundante, irrelevante Informationen oder sind durch starkes Rauschen „verunreinigt“, so werden die Generalisierung und der Erkenntnisgewinn der „Lernphase“ deutlich erschwert. Die Datenvorverarbeitung besitzt daher eine wesentliche Bedeutung [12].

Beispiel Prozesslernfabrik – Digitalisierung der Bandsäge und Erstellung der Datensets

Durch Literaturrecherche mit Fokus auf Verschleißvorhersage bei Sägen wurden charakteristische Parameter für das Daten- und Sensorkonzept definiert, wie z.B. Schwingungen, Temperatur oder Leistungsaufnahme [13, 14]. Die Bestimmung der Eingangsdaten und Zielwerte erfolgt in Abhängigkeit der Sägebandfehler, wobei hypothesengetrieben vorgegangen wird: So führt „Zahnverschleiß“ beispielsweise zu verändertem, kontinuierlichem Materialabtrag und Schnittverhalten, was sich im Schwingungsverhalten durch einen veränderten Kraftverlauf auswirkt [15]. Zielwerte für „Zahnabriss“ und „Bandabriss“ können durch makroskopische Betrachtung bestimmt werden, während „Zahnverschleiß“ durch mikroskopische Erfassung, zum Beispiel der Zahnhöhe quantifizierbar ist [15]. Das für den Demonstrator gewählte Sensorkonzept kann Bild 2 entnommen werden (zu Testzwecken wurde ein „Maximalset“ unterschiedlicher Sensorik ausgewählt, das in Folgeversuchen „herunterskaliert“ wird).

Um das Normalverhalten der Säge bei unverschleißtem Sägeband zu erfassen und einen kontinuierlichen Verschleißverlauf aufzuzeichnen, wurde im Folgenden ein Vollversuch gestartet, bei dem durch zahlreiche Schnitte ein Totalverschleiß des Sägebandes unter realen Produktionsbedingungen provoziert werden sollte. In Summe wurden 650 Schnitte durchgeführt. Entgegen der Erwartung konnte nur moderater Zahnverschleiß gemessen werden, der durch einen zum Ende des Experiments auftretenden Bandriss überschattet wurde. Trotz des relativ plötzlichen Auftretens des Bandrisses (dieser war erst mit Schnitt 646 hörbar), kann ab Schnitt 630 eine Veränderung der gemessenen Maximalwerte axialer Vibrationsaufnahme, Leistungsaufnahme und Temperatur verzeichnet werden. Im Vergleich zu den vorher gemessenen „Normalwerten“ verdeutlicht der simultane Anstieg von Leistungs-, Temperatur- und Vibration in axialer Richtung eine Anomalie am Sägeband, die auf Schläge durch den ungleichmäßigen Materialeingriff des sich ausbreitenden Bandrisses zurückzuführen ist. Der Vorlauf von 20 Schnitten stellt das Ergebnis einer Ausreißeruntersuchung basierend auf dem Median der absoluten Abweichungen (MAD) gem. [16] dar: Ab Schnitt 630 liegt eine signifikante Veränderung zu normalem Verhalten vor, wie in Bild 3 gezeigt ist.

Systemaufbau, Training und Evaluation

Die Datengrundlage wird genutzt, um den ausgewählten Algorithmus zu trainieren, der anschließend – sofern das Training erfolgreich war – die Zielwerte aus anlie-

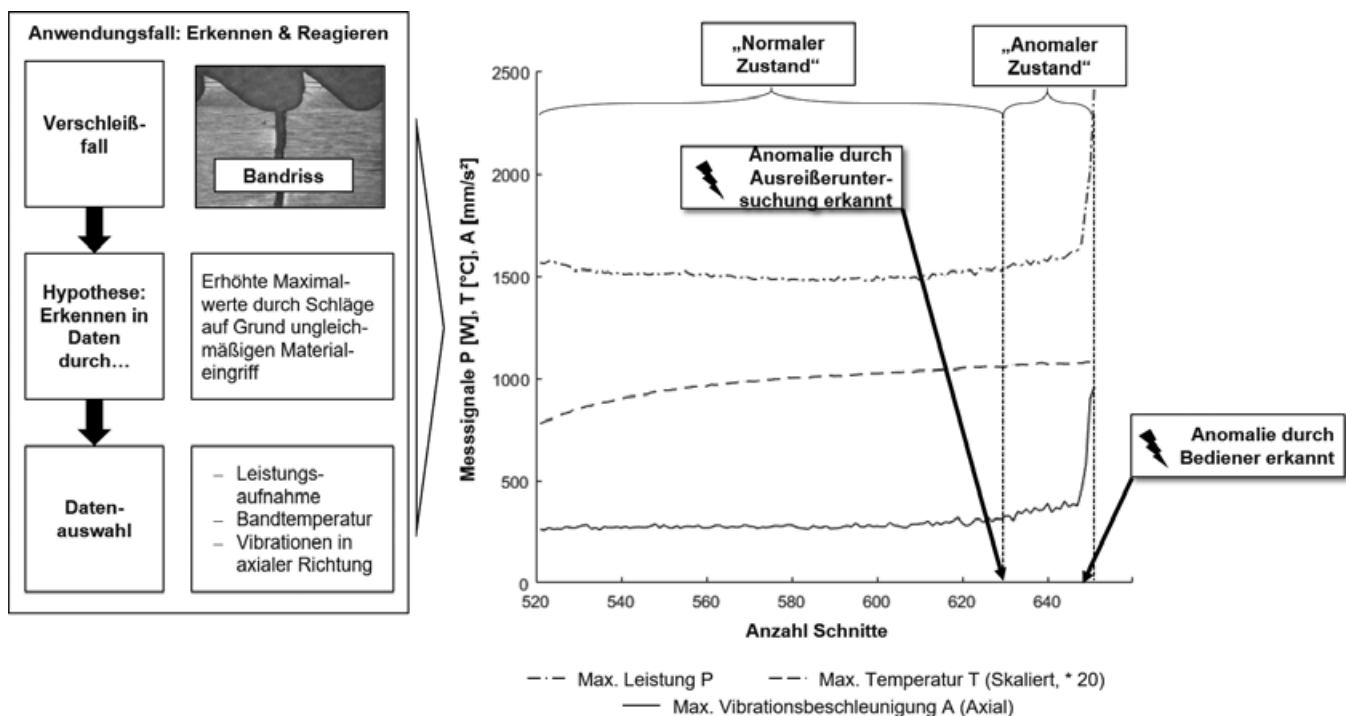


Bild 3. Aufzeichnung charakteristischer Messdaten (Auszug) während des Vollversuchs entlang 650 Schnitte

genden Eingangswerten approximiert. Je nach Problemstellung bieten die Verfahren des maschinellen Lernens unterschiedlich gute Ergebnisse hinsichtlich Genauigkeit, Präzision und Robustheit der Vorhersagen. Einen Vergleich unterschiedlicher Verfahren hinsichtlich wesentlicher Eigenschaften bietet [4].

Trainierte Systeme müssen hinsichtlich ihrer Eignung evaluiert werden, die richtigen Ergebnisse in geforderter Güte ausgeben zu können. Dies hat insbesondere in Abhängigkeit der definierten Zielgröße und einer möglichen Prozessintegration zu geschehen, da die Systeme letztlich zur Steuerung von Optimierungsprozessen (z.B. vorbeugende Instandhaltung) verwendet werden und daher Anforderungen an deren Prozessstabilität unterliegen. Unterschiedliche Prognoseparameter können sich beispielsweise auf den erzielbaren Nutzen einer zustandsabhängigen Instandhaltung auswirken (z.B. Anzahl falscher Prognosen), was dazu führen kann, dass analoge Instandhaltungsstrategien (z.B. zeitbasiert) im Vergleich doch einen höheren Nutzen erzielen [17].

Beispiel Prozesslernfabrik – Auswahl, Training und Evaluation eines Verfahrens des maschinellen Lernens

Als Methode des maschinellen Lernens werden künstliche neuronale Netze (Artificial Neural Network – ANN) ausge-

wählt, da sie eine hohe Genauigkeit sowie eine hohe Trainingsgeschwindigkeit aufweisen. ANN sind den in der Natur vorkommenden neuronalen Strukturen nachempfunden und bestehen aus mehreren sogenannten Neuronen, die eine einfache Informationsweitergabe und -verarbeitung ermöglichen. Ein Netz dieser Neuronen (sog. „Hidden Layer“) verknüpft Eingangs- und Zielwerte, wobei durch einen automatischen Trainingsvorgang dieser „Hidden Layer“ so eingestellt wird, dass eine Approximation der Zielwerte aus den vorhandenen Eingangswerten erzeugt wird. Zwecks Vertiefung wird auf die zitierte Literatur verwiesen [4].

Use-Case: Verfügbarkeit erhöhen durch „Erkennen & Reagieren“ des Bandrisses

Als Beispiel einer automatischen Identifikation von Verschleißzuständen wird im Folgenden der Fall „Bandriss“ näher betrachtet. In den Experimenten erfasste Daten wurden zum Training multipler ANNs verwendet. Eingangswerte des ANN sind Leistung, Temperatur und Schwingung in axialer Richtung (vgl. Bild 3). Als Zielwert wurde den ANNs ein Vorlauf von 20 Schnitten zum Versagenszeitpunkt (basierend auf der Anomalie ab Schnitt 630) mit linear abnehmendem Verlauf vorgegeben. Als Grundlage des ANN wurde ein „Nonlinear Autoregressive with Exogenous Input“ (NARX)-Netz-

werk verwendet, das neben den aktuellen Eingabewerten ebenfalls vergangene Werte bis zu einem definierten Zeitpunkt („Delay“) berücksichtigt und gute Eignung zur Vorhersage dynamischer, nichtlinearer Systemzusammenhänge besitzt [18]. Unterschiedliche Netzwerkarchitekturen wurden getestet, bei denen die Anzahl Neuronen sowie der Delays verändert wurden. Geringste Abweichungen von den Zielwerten und beste Generalisierung der Vorhersage wurden mit drei Neuronen im „Hidden-Layer“ und zwei „Delays“ erzielt.

Bild 4 gibt den vorhergesagten Verlauf der Zielwerte wieder. Zu erkennen ist, dass der Anomaliebereich 20 Schnitte vor Bandabriss erkannt wird, die Vorhersage jedoch teilweise überschwingt und fluktuierende Werte bis zum Bandabriss vorhersagt. Das Überschwingen kann durch das Verfahren des gleitenden Durchschnitts gedämpft werden. Trotz der Vorhersagefehler bietet das ANN eine effektive Anomalieerkennung und gibt dem Maschinenbediener Vorlaufzeit, auf den kommenden Bandriss zu reagieren.

Prozessintegration

Eine erfolgreiche Evaluation vorausgesetzt, kann das digitale Prozessüberwachungssystem in den Gesamtprozess eingeführt werden. Hierbei ist in Abhängigkeit des „Supportprozesses“ (z.B. des In-

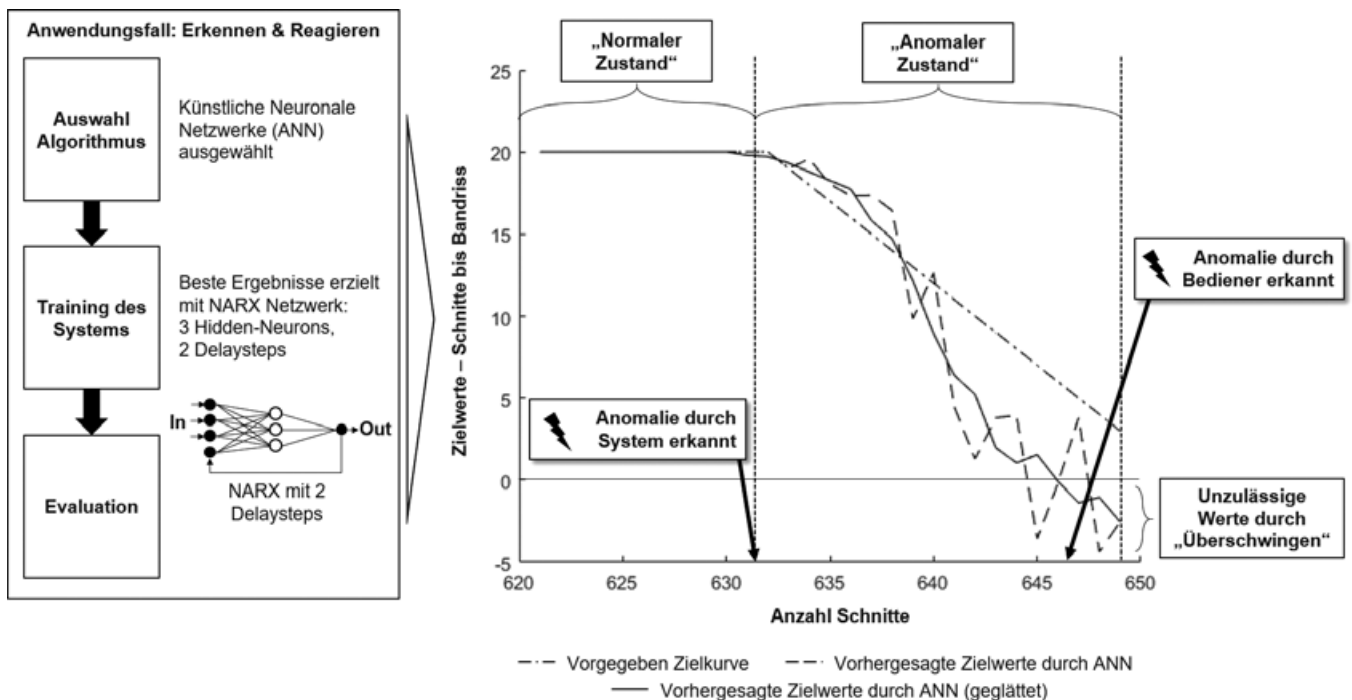


Bild 4. Vergleich Vorhersage ANN (absolut/geglättet) mit vorgegebenen Zielwerten

standhaltungsprozesses) ein geeigneter Übergabepunkt in zeitlicher (Wann wird der Techniker informiert?) wie auch technisch-prozessualer Dimension (Wie wird der Techniker informiert?) zu definieren. Im Falle von Prozessveränderungen, die die untersuchten Kausalzusammenhänge verändern (z.B. deutliche Veränderung des Lastprofils auf der Maschine), ist eine Reevaluierung der Prozessüberwachung durchzuführen, die ggf. durch die Prozessveränderung unwirksam geworden ist [9].

Beispiel Prozesslernfabrik – Prozessintegration durch Werkerassistenzsystem und Datenbrille

Als Empfänger der Verschleißmeldungen wurde der Maschinenbediener ausgewählt, der über eine grafische Bedienoberfläche auf den drohenden Bandfehler und Verschleißzustand hingewiesen wird. Um den Austausch des Sägebandes digital zu unterstützen kann der Maschinenbediener zusätzlich eine Datenbrille verwenden, die auftragspezifische Anweisungen in Schrift- und Bildform im Sichtfeld des Maschinenbediener anzeigt.

Zusammenfassung und nächste Schritte

In den initialen Versuchen konnte mithilfe der entwickelten Methode ein funktionierender Demonstrator der digitalen Prozessüberwachung entwickelt werden.

Hinsichtlich des Anwendungsfalles „Erkennen und Reagieren“ – wobei ebenfalls eine kurze Vorlaufzeit realisiert wurde – können erste Erfolge vorgewiesen werden. Das verwendete Verfahren des maschinellen Lernens kann im Demonstrator eingesetzt werden, um zukünftig im realen Prozess auf die erlernten Verschleißzustände hinzuweisen. Dieses aus Maschinendaten automatisch erstellte Wissen kann der Maschinenbediener für präventives Handeln verwenden und somit die Verfügbarkeit der Maschine steigern.

Um eine vollständige Evaluation der Eignung unter unterschiedlichen Szenarien und Beurteilung der Prognosegüte durchzuführen, sind zusätzliche Datenreihen zu erfassen: Für den Bandanriss war letztlich nur eine Datenreihe zur Auswertung verfügbar, andere Verschleißzustände wurden noch nicht vollständig erfasst. Daher sind weitere Versuche nötig, um die Belastbarkeit der Aussagen zu erhöhen.

In diesen weiteren Versuchen kann neben unterschiedlichen Verschleißzuständen auch der Einfluss der Integration des Systems auf den Gesamtprozess evaluiert werden. Beispielsweise können unterschiedliche Prognosegüten und deren Einfluss auf die Prozessstabilität untersucht werden.

Literatur

1. Feldmann, S.; Herweg, O.; Rauen, H.; Synek, P.: Predictive Maintenance, Service der Zukunft – und wo er wirklich steht. Studienergebnisse, Roland Berger, München 2017, Verfügbar unter www.rolandberger.com/de/Publications/pub_predictive_maintenance_2017.html [Letzter Abruf: 10.8.2017]
2. Gölzer, P.: Big Data in Industrie 4.0 – Eine strukturierte Aufarbeitung von Anforderungen, Anwendungsfällen und deren Umsetzung. Friedrich-Alexander-Universität Erlangen-Nürnberg, Open Access Publikation 2017, S. 125–164
3. Reitmaier, T.: Aktives Lernen für Klassifikationsprobleme unter der Nutzung von Strukturinformationen. In: Hölldobler, S. et al. (Hrsg.): Ausgezeichnete Informatikdissertationen 2015, Lecture Notes in Informatics (LNI), Gesellschaft für Informatik, Bonn 2016, S. 239–248
4. Kotsiantis, S.B.: Supervised Machine Learning: A Review of Classification Techniques. Informatica 31 (2007), S. 249–268
5. Widodo, A.; Yang, B.-S.: Support Vector Machine in Machine Condition Monitoring and Fault Diagnosis. Mechanical Systems and Signal Processing 21 (2007) 6, S. 2560–2574
6. Lee, J.; Wu, F.; Zhao, W.; Ghaffari, M.; Liao, L.; Siegel, D.: Prognostics and Health Management Design for Rotary Machinery Systems – Reviews, Methodology and Applications. Mechanical Systems and Signal Processing 42 (2014), S. 314–334 DOI: 10.1016/j.ymssp.2013.06.004

7. Meudt, T.; Metternich, J.; Abele, E.: Value Stream Mapping 4.0. CIRP Annals – Manufacturing Technology 66 (2017), S. 413–416
8. Rößler, M. P.; Abele, E.: Uncertainty in the Analysis of the Overall Equipment Effectiveness on the Shop Floor. IOP Conference Series: Materials Science and Engineering 46 (2013), S. 1–9
DOI: 10.1088/1757-899X/46/1/012019
9. Hölbfner, S. A.: Modell zur Auswahl von Instandhaltungsstrategien in anlageintensiven Industriebetrieben. Montanuniversität Leoben, Lehrstuhl Wirtschafts- und Betriebswissenschaften, Open Access Publikation 2014, S. 105–149
10. Biedermann, H.: Lean Smart Maintenance: wertschöpfende, lernorientierte und ressourceneffiziente Instandhaltung. In: Biedermann, H. (Hrsg.): Lean Smart Maintenance, Konzepte, Instrumente und Anwendungen für eine effiziente und intelligente Instandhaltung. TÜV Media GmbH, Köln 2016, S. 19–29
DOI: 10.1007/978-3-658-12097-9_7
11. Sarwar, M.; Haider, J.; Persson, M.: Scientific Evaluation of Cutting-Off Process in Bandsawing. In: Scientific Proceedings, 8th International Congress – Machines, Technologies, Materials, Bulgarien 2011, S. 29–32
12. Kotsiantis, S. B.; Kanellopoulos, D.; Pintelas, P. E.: Data Preprocessing for Supervised Learning. International Journal of Computer, Electrical, Automation, Control and Information Engineering 12 (2007), S. 4091–4096
13. Saglam, H.: Tool Wear Monitoring in Bandsawing Using Neural Networks and Taguchi's Design of Experiments. The International Journal of Advanced Manufacturing Technology 55 (2011), S. 969–982
DOI: 10.1007/s00170-010-3133-1
14. Hashemian, H. M.: State-of-the-Art Predictive Maintenance Techniques. IEEE Transactions on Instrumentation and Measurement 60 (2011) 10, S. 226–236
15. Dietrich, J.: Praxis der Zerspantechnik. Springer Fachmedie, Wiesbaden 2016, S. 25–31
DOI: 10.1007/978-3-658-14053-3
16. Leys, C.; Ley, C.; Klein, O.; Bernard, P.; Licata, L.: Detecting Outliers. Journal of Experimental Social Psychology 49 (2013) 4, S. 764–766
17. Jonge, B. de; Teunter, R.; Tinga, T.: The Influence of Practical Factors on the Benefits of Condition-based Maintenance over Time-based Maintenance. Reliability Engineering & System Safety 158 (2017), S. 21–30
DOI: 10.1016/j.res.2016.10.002
18. Diaconescu, E.: The Use of NARX Neural Networks to Predict Chaotic Time Series. WSEAS Transactions on Computer Research 3 (2008) 3, S. 182–191

Die Autoren dieses Beitrags

Alexander Busse, M. Sc., und Dipl.-Wirtsch.-Ing. Tobias Meudt sind Wissenschaftliche Mitarbeiter der Forschungsgruppe Center für industrielle Produktivität (CiP) am Institut für Produktionsmanagement, Technologie und Werkzeugmaschinen (PTW) an der Technischen Universität Darmstadt (TU Darmstadt).

Prof. Dr.-Ing. Joachim Metternich ist Institutsleiter des PTW an der TU Darmstadt.

Summary

Availability and Quality Enhancement via Digital Process Monitoring – A Structured Implementation Approach. Machine learning helps to discover correlations in data automatically and can be used to stabilize production processes. A structured implementation approach is needed that defines data requirements and benchmarks the digital value with analogue problem solving methods. A structured approach was developed and tested at the institute PTW at TU Darmstadt that helps to facilitate the implementation of machine learning in production.

Bibliography

DOI 10.3139/104.111784

ZWF 112 (2017) 10; page 652–657

© Carl Hanser Verlag GmbH & Co. KG

ISSN 0032–678X